

Faculté des sciences Tunis El Manar / Université de Tunis El Manar

Filière : Ingénierie des Data Science IDS1

Module : Statistique multivariée

Analyse en Composantes Principales
des annonces Airbnb à Paris

Réduction dimensionnelle et interprétation des facteurs structurants

---

Méthode principale : Analyse en Composantes Principales (ACP)
Dataset : Airbnb Paris
Objectif : Identifier les dimensions latentes structurant les annonces

Réalisé par : Laadhar Edam

Encadré par : Mme Thabet Chahnez

Année : Année universitaire 2025–2026

Table des matières

1 Introduction **5**

2 Présentation théorique de l'ACP **6**

2.1 Principe général 6

2.2 Matrice de covariance et corrélation 6

2.3 Décomposition spectrale 7

2.4 Composantes principales 7

2.5 Variance expliquée 7

2.6 Interprétation géométrique 8

2.7 Limites de l'ACP 8

2.8 Implémentation 8

3 Problématique **9**

4 Application au dataset Airbnb **10**

4.1 Présentation du dataset 10

4.2 Analyse descriptive des variables 11

4.2.1 Description des variables initiales 11

4.2.2 Synthèse descriptive des variables quantitatives retenues 11

4.2.3 Lecture statistique avant ACP 11

4.3 Préparation des données 14

4.4 Analyse de la matrice de corrélation 14

4.5 Standardisation 16

5 Résultats **17**

5.1 Variance expliquée 17

5.2 Analyse des loadings 19
5.2.1 Plan PC1–PC2 19
5.2.2 Plan PC1–PC3 21
5.3 Projection des individus 21

6 Interprétation des résultats **24**
6.1 Interprétation de PC1 : standing et capacité 24
6.2 Interprétation de PC2 : conditions de location 24
6.3 Interprétation de PC3 : activité et popularité 24
6.4 Synthèse métier 25

7 Améliorations possibles **26**

8 Conclusion **27**

Table des figures

4.1 Extrait du dataframe brut avant préparation 10

4.2 Matrice de corrélation des variables quantitatives retenues pour l'ACP 15

5.1 Variance expliquée par composante principale 17

5.2 Variance cumulée des composantes principales 18

5.3 Extrait du tableau de variance expliquée par composante 18

5.4 Extrait du tableau des loadings de PC1 à PC5 19

5.5 Loadings des variables sur le plan PC1–PC2 20

5.6 Loadings des variables sur le plan PC1–PC3 21

5.7 Sous-tableau des loadings pour le plan PC1–PC3 22

5.8 Projection des individus sur le plan factoriel PC1–PC2 22

5.9 Projection des individus selon le type de logement 23

Liste des tableaux

4.1 Résumé général du dataset 10
4.2 Description des variables disponibles dans le dataset 12
4.3 Synthèse descriptive des variables quantitatives retenues pour l'ACP 13
4.4 Variables retenues pour l'ACP 14

5.1 Choix des composantes selon l'objectif d'analyse 18

6.1 Synthèse finale de l'interprétation des axes principaux 25

Chapitre 1

Introduction

Avec le développement des plateformes numériques de location courte durée, les données issues d'Airbnb permettent d'étudier finement les caractéristiques des logements proposés : prix, capacité, nombre de chambres, frais, durée minimale de séjour ou encore activité de l'annonce. Ces informations sont multidimensionnelles et difficiles à interpréter directement lorsqu'elles sont observées variable par variable.

Dans ce contexte, l'Analyse en Composantes Principales (ACP) constitue une méthode adaptée pour réduire la complexité des données quantitatives tout en conservant une partie importante de l'information. Elle permet de synthétiser plusieurs variables corrélées en un nombre réduit de composantes principales interprétables.

Objectif

L'objectif de ce projet est d'appliquer une ACP sur un dataset Airbnb à Paris afin d'identifier les principales dimensions latentes qui structurent les annonces et d'en proposer une interprétation statistique et métier.

Chapitre 2

Présentation théorique de l'ACP

L'Analyse en Composantes Principales (ACP) est une méthode descriptive de statistique multivariée largement utilisée pour analyser des données quantitatives multidimensionnelles. Son objectif principal est de réduire la dimension d'un jeu de données tout en conservant au maximum l'information contenue dans les variables initiales.

Elle consiste à transformer un ensemble de variables corrélées en un nouveau système de variables non corrélées, appelées **composantes principales**, qui sont des combinaisons linéaires des variables d'origine. Ces nouvelles variables sont ordonnées de manière à expliquer une part décroissante de la variance totale.

2.1 Principe général

Soit une matrice de données X de dimension $(n \times p)$, où n représente le nombre d'individus et p le nombre de variables quantitatives.

Avant l'application de l'ACP, les variables sont généralement **centrées et réduites** afin d'éliminer les effets d'échelle et rendre les variables comparables :

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \tag{2.1}$$

où $\bar{x}_j$ est la moyenne de la variable j et s_j son écart-type.

Cette transformation permet de travailler sur des variables de moyenne nulle et de variance unitaire.

2.2 Matrice de covariance et corrélation

L'ACP repose ensuite sur l'analyse de la structure de dépendance entre les variables, représentée par :

— la **matrice de covariance** (si les variables sont homogènes),
— ou la **matrice de corrélation** (si les variables sont standardisées).

Dans ce projet, l'utilisation de la matrice de corrélation est privilégiée, car les variables sont exprimées dans des unités différentes.

2.3 Décomposition spectrale

L'étape centrale de l'ACP consiste à effectuer une **décomposition en valeurs propres** de la matrice de covariance (ou corrélation).

Soit R la matrice de corrélation :

$$R = Q\Lambda Q^T \tag{2.2}$$

où :

— Q est la matrice des vecteurs propres (directions principales),
— Λ est la matrice diagonale des valeurs propres.

Les valeurs propres λ_k mesurent la quantité de variance expliquée par chaque composante principale.

2.4 Composantes principales

Chaque composante principale est définie comme une combinaison linéaire des variables initiales :

$$PC_k = a_{1k}X_1 + a_{2k}X_2 + \cdots + a_{pk}X_p \tag{2.3}$$

Les coefficients a_{jk} sont appelés **loadings**. Ils représentent le poids de chaque variable dans la construction de la composante k.

Les composantes principales possèdent deux propriétés fondamentales :

— elles sont **orthogonales** entre elles (non corrélées),
— elles maximisent successivement la variance expliquée.

2.5 Variance expliquée

La qualité de la représentation des données est mesurée par la **variance expliquée**. La proportion de variance expliquée par la composante k est donnée par :

$$\frac{\lambda_k}{\sum_{j=1}^{p} \lambda_j} \tag{2.4}$$

La **variance cumulée** permet de déterminer le nombre de composantes à retenir pour représenter les données de manière satisfaisante.

2.6 Interprétation géométrique

D'un point de vue géométrique, l'ACP peut être interprétée comme une rotation du système d'axes initial vers un nouveau repère dans lequel :

— le premier axe maximise la dispersion des individus,
— les axes suivants capturent l'information restante de manière orthogonale.

Cette transformation permet de projeter les données dans un espace de dimension réduite tout en conservant les structures essentielles.

2.7 Limites de l'ACP

Malgré ses avantages, l'ACP présente certaines limites :

— elle ne capture que des relations linéaires entre les variables ;
— elle est sensible aux valeurs extrêmes (outliers) ;
— l'interprétation des composantes peut parfois être délicate.

2.8 Implémentation

Dans ce projet, l'ACP est implémentée à l'aide de la bibliothèque `scikit-learn`, qui permet de réaliser efficacement :

— la standardisation des données,
— la décomposition en composantes principales,
— le calcul des variances expliquées et des loadings.

Insight analytique

L'ACP constitue un outil puissant de réduction dimensionnelle permettant de transformer un ensemble complexe de variables corrélées en un nombre réduit de dimensions interprétables, facilitant ainsi l'analyse et la visualisation des données.

Chapitre 3

Problématique

La problématique retenue est la suivante :

Résultat clé

Quels sont les principaux facteurs latents qui structurent les annonces Airbnb à Paris, et dans quelle mesure les variables quantitatives peuvent-elles être résumées par un petit nombre de composantes principales interprétables ?

Cette question implique deux objectifs complémentaires :

— réduire la dimension du jeu de données initial ;

— interpréter les composantes obtenues dans un contexte réel lié au marché Airbnb.

Chapitre 4

Application au dataset Airbnb

4.1 Présentation du dataset

Le jeu de données étudié contient **8 000 observations** et **19 variables** décrivant des annonces Airbnb à Paris. Les variables sont de nature mixte : certaines sont quantitatives, tandis que d'autres sont qualitatives.

TABLE 4.1 – Résumé général du dataset

Élément	**Description**
Nombre d'observations	8 000
Nombre de variables initiales	19
Type de données	Mixtes : quantitatives et qualitatives
Méthode utilisée	ACP sur variables quantitatives
Nombre de variables retenues pour l'ACP	14

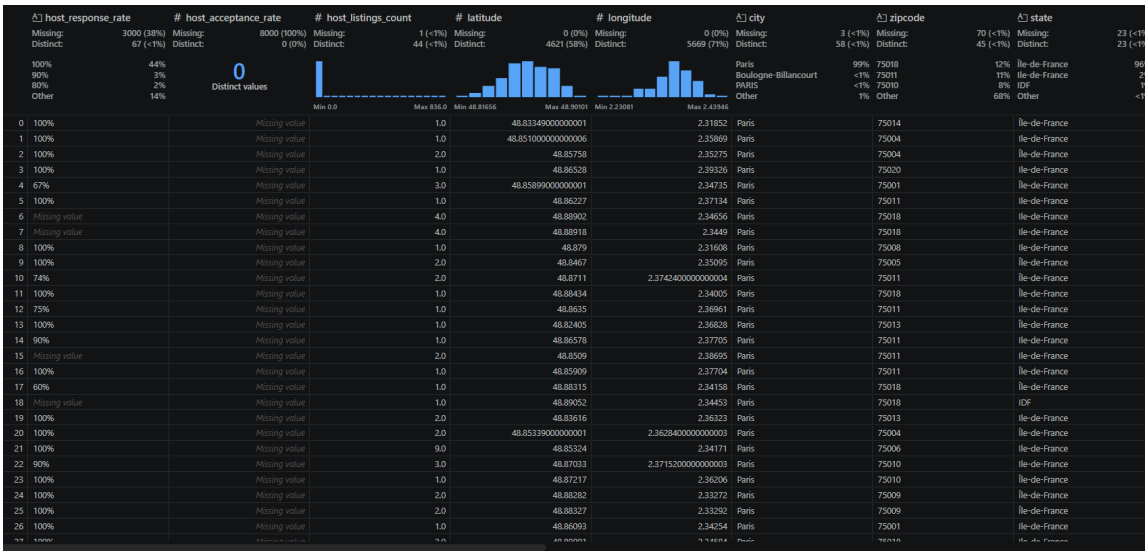


FIGURE 4.1 – Extrait du dataframe brut avant préparation

L'aperçu des données brutes montre que le dataset contient à la fois des variables numériques, des variables monétaires, des pourcentages et des variables catégorielles. Cette structure confirme la nécessité d'une étape de nettoyage avant toute analyse multivariée. En particulier, les variables exprimées sous forme de chaînes de caractères doivent être converties pour pouvoir être intégrées dans l'ACP.

4.2 Analyse descriptive des variables

Avant d'appliquer l'ACP, une analyse descriptive a été réalisée afin de comprendre la nature des variables, leur rôle dans l'analyse et les traitements nécessaires. Cette étape est essentielle, car l'ACP est sensible aux unités de mesure, aux valeurs manquantes et aux valeurs extrêmes.

4.2.1 Description des variables initiales

Ce tableau montre que le dataset contient plusieurs familles d'information : la structure du logement, les variables monétaires, les contraintes de réservation, la localisation et l'activité de l'annonce. Cette diversité justifie l'utilisation d'une méthode factorielle, car l'objectif n'est pas seulement d'analyser chaque variable séparément, mais de comprendre les relations globales entre elles.

4.2.2 Synthèse descriptive des variables quantitatives retenues

4.2.3 Lecture statistique avant ACP

L'analyse descriptive met en évidence trois points importants. D'abord, les variables quantitatives retenues ne sont pas exprimées dans les mêmes unités : certaines correspondent à des montants monétaires, d'autres à des nombres de pièces, à des coordonnées géographiques ou à des durées de séjour. Ensuite, certaines variables peuvent présenter des valeurs extrêmes, notamment le prix, le dépôt de garantie, les frais de ménage ou le nombre maximal de nuits. Enfin, plusieurs variables décrivent des dimensions proches, comme la capacité d'accueil, le nombre de chambres et le nombre de lits.

Insight analytique

L'analyse descriptive confirme que les données sont hétérogènes et multidimensionnelles. Elle justifie donc deux choix méthodologiques majeurs : la sélection des variables quantitatives pour l'ACP et leur standardisation avant le calcul des composantes principales.

TABLE 4.2 – Description des variables disponibles dans le dataset

Variable	**Nature**	**Rôle dans l'analyse**
`host_response_rate`	Quantitative	Taux de réponse de l'hôte, utilisé comme indicateur de réactivité.
`host_acceptance_rate`	Quantitative	Variable supprimée, car entièrement vide dans le dataset observé.
`host_listings_count`	Quantitative	Nombre d'annonces gérées par l'hôte ; indicateur de professionnalisation.
`latitude`	Quantitative	Coordonnée géographique permettant de situer l'annonce.
`longitude`	Quantitative	Coordonnée géographique permettant de situer l'annonce.
`city`	Qualitative	Variable descriptive non intégrée dans l'ACP principale.
`zipcode`	Qualitative	Variable géographique catégorielle, conservée pour lecture descriptive.
`state`	Qualitative	Variable administrative non intégrée dans l'ACP principale.
`room_type`	Qualitative	Type de logement utilisé pour interpréter la projection des individus.
`accommodates`	Quantitative	Capacité d'accueil du logement.
`bedrooms`	Quantitative	Nombre de chambres.
`bathrooms`	Quantitative	Nombre de salles de bain.
`beds`	Quantitative	Nombre de lits disponibles.
`price`	Quantitative	Prix de l'annonce après conversion en valeur numérique.
`cleaning_fee`	Quantitative	Frais de ménage après conversion en valeur numérique.
`security_deposit`	Quantitative	Dépôt de garantie après conversion en valeur numérique.
`minimum_nights`	Quantitative	Durée minimale de séjour imposée.
`maximum_nights`	Quantitative	Durée maximale de séjour autorisée.
`number_of_reviews`	Quantitative	Nombre d'avis, indicateur d'activité et de popularité.

TABLE 4.3 – Synthèse descriptive des variables quantitatives retenues pour l'ACP

Groupe	**Variables**	**Interprétation descriptive**
Capacité du logement	`accommodates`, `bedrooms`, `bathrooms`, `beds`	Ces variables décrivent la taille et le niveau d'équipement du logement. Elles sont généralement liées entre elles : un logement pouvant accueillir davantage de personnes possède souvent plus de chambres et de lits.
Variables monétaires	`price`, `cleaning_fee`, `security_deposit`	Ces variables décrivent le coût de l'annonce. Elles peuvent présenter une forte dispersion, car les logements Airbnb varient fortement selon la taille, l'emplacement et le niveau de standing.
Gestion de l'annonce	`host_response_rate`, `host_listings_count`	Ces variables donnent une indication sur la réactivité de l'hôte et sur son degré de professionnalisation.
Contraintes de réservation	`minimum_nights`, `maximum_nights`	Ces variables caractérisent les règles imposées par l'hôte. Elles peuvent contenir des valeurs extrêmes, notamment pour les durées maximales de séjour.
Localisation	`latitude`, `longitude`	Ces coordonnées permettent de différencier les annonces selon leur position géographique dans Paris.
Activité	`number_of_reviews`	Cette variable mesure l'activité observée de l'annonce. Elle est souvent asymétrique, avec beaucoup d'annonces peu commentées et quelques annonces très actives.

4.3 Préparation des données

Avant d'appliquer l'ACP, une étape de préparation a été réalisée afin d'obtenir un tableau quantitatif propre et exploitable.

La variable `host_acceptance_rate` a été supprimée, car elle était entièrement vide. Plusieurs variables stockées sous forme textuelle ont ensuite été converties en variables numériques :

— `host_response_rate`, exprimée initialement sous forme de pourcentage ;
— `price`, `cleaning_fee` et `security_deposit`, exprimées sous forme monétaire.

Les variables catégorielles telles que `city`, `zipcode`, `state` et `room_type` n'ont pas été intégrées dans l'ACP principale, car l'ACP classique est adaptée aux variables quantitatives continues.

Table 4.4 – Variables retenues pour l'ACP

Catégorie	**Variables**
Capacité et structure	`accommodates`, `bedrooms`, `bathrooms`, `beds`
Variables monétaires	`price`, `cleaning_fee`, `security_deposit`
Gestion et contraintes	`host_response_rate`, `host_listings_count`, `minimum_nights`, `maximum_nights`
Localisation et activité	`latitude`, `longitude`, `number_of_reviews`

Les valeurs manquantes restantes ont été imputées par la médiane. Ce choix est robuste face aux valeurs extrêmes, notamment dans les variables comme le prix, le dépôt de garantie ou les durées de séjour.

Insight analytique

Après préparation, le jeu de données final contient 8 000 observations et 14 variables quantitatives, sans valeurs manquantes. Il est donc prêt pour la standardisation puis l'application de l'ACP.

4.4 Analyse de la matrice de corrélation

Avant d'appliquer l'ACP, une matrice de corrélation a été calculée sur les variables quantitatives retenues. Cette étape permet d'observer les relations linéaires entre les variables et de vérifier l'existence de redondances, condition dans laquelle l'ACP devient particulièrement pertinente.

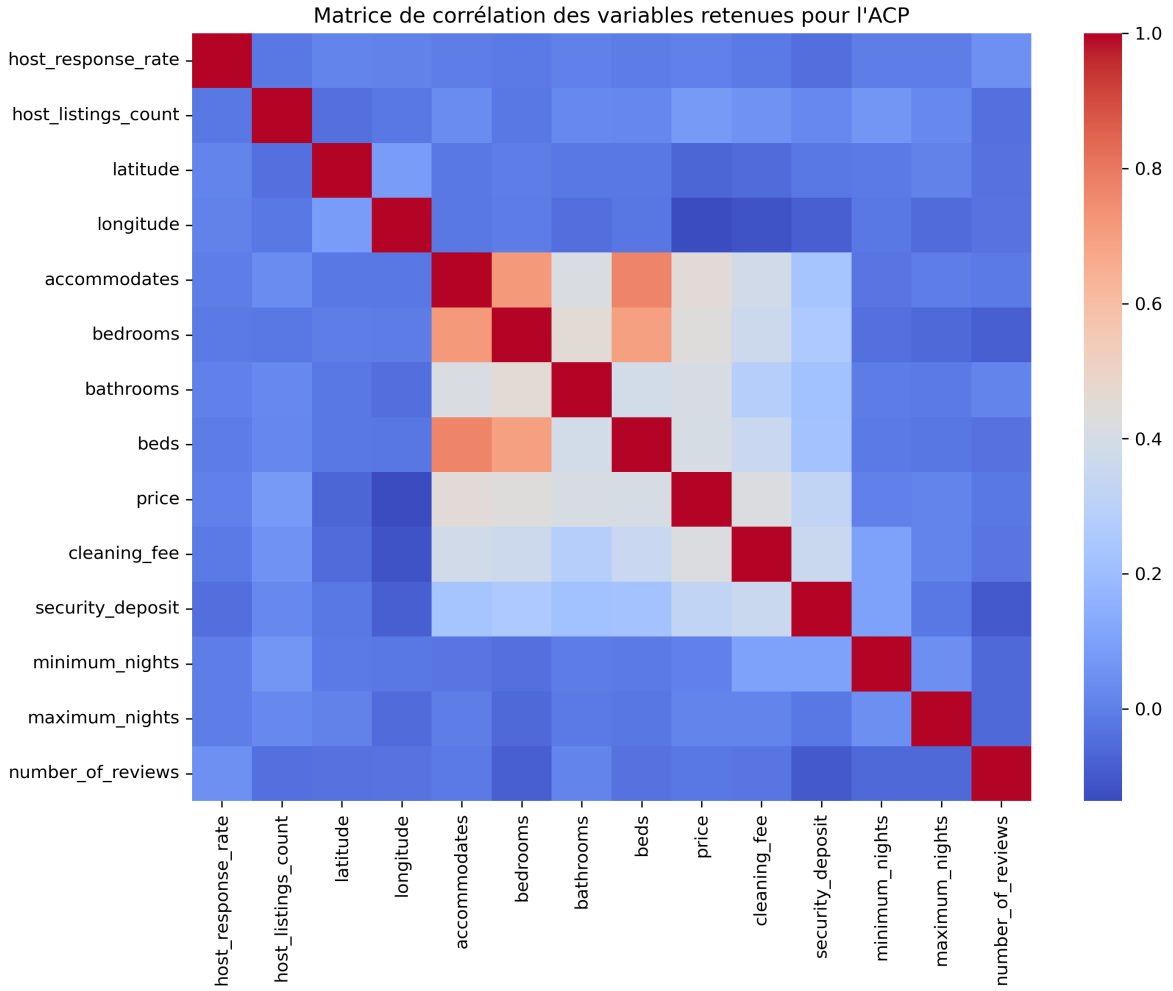


FIGURE 4.2 – Matrice de corrélation des variables quantitatives retenues pour l'ACP

La matrice de corrélation met en évidence plusieurs associations importantes. Les variables liées à la capacité du logement, telles que `accommodates`, `bedrooms`, `bathrooms` et `beds`, présentent des corrélations positives. De même, les variables monétaires comme `price`, `cleaning_fee` et `security_deposit` sont liées entre elles.

Ces relations confirment que certaines variables apportent une information partiellement redondante. L'ACP est donc adaptée dans ce contexte, car elle permet de résumer ces groupes de variables corrélées en composantes principales plus synthétiques.

Insight analytique

La matrice de corrélation constitue une étape de diagnostic importante : elle montre que plusieurs variables évoluent conjointement, ce qui justifie l'utilisation de l'ACP pour réduire la dimension tout en conservant les structures principales des données.

4.5 Standardisation

La standardisation est indispensable, car les variables du dataset sont exprimées dans des unités différentes : prix en dollars, nombre de chambres, coordonnées géographiques, nombre de nuits, etc. Sans standardisation, les variables ayant les plus grandes amplitudes pourraient dominer artificiellement l'ACP.

Chaque variable a donc été centrée autour de 0 et réduite à un écart-type proche de 1 avant le calcul de l'ACP.

Point méthodologique

La standardisation permet de donner le même poids initial à toutes les variables. Ainsi, une variable comme `price`, qui possède des valeurs numériques élevées, ne domine pas artificiellement une variable comme `bedrooms` ou `bathrooms`.

Chapitre 5

Résultats

5.1 Variance expliquée

L'ACP a été appliquée aux 14 variables quantitatives standardisées. Le nombre total de composantes principales produites est donc égal au nombre de variables initiales retenues, soit 14 composantes.

La figure suivante présente la variance expliquée par chaque composante ainsi que la variance cumulée.

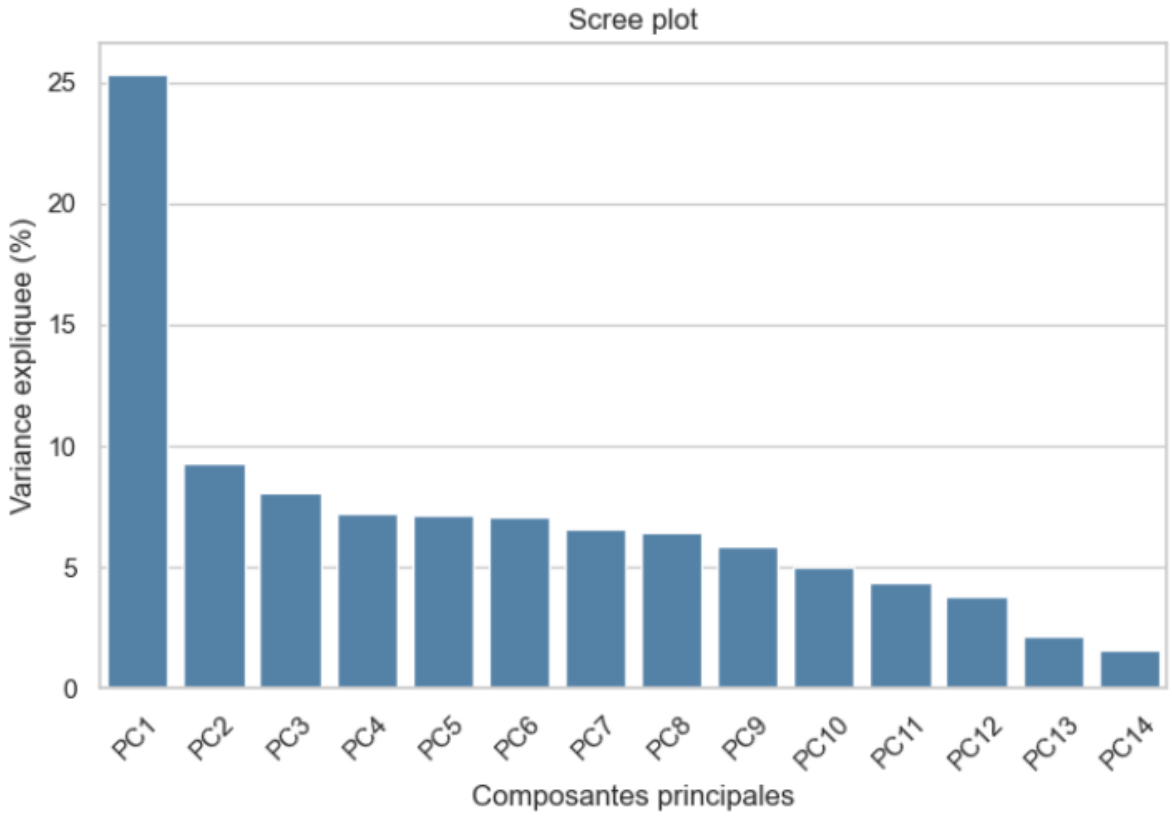


FIGURE 5.1 – Variance expliquée par composante principale

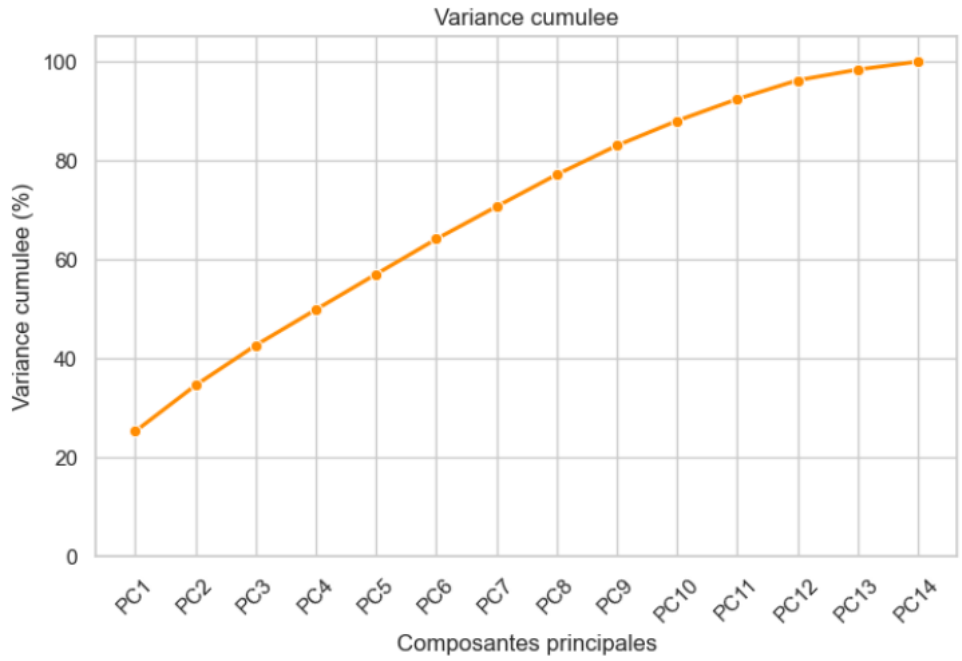
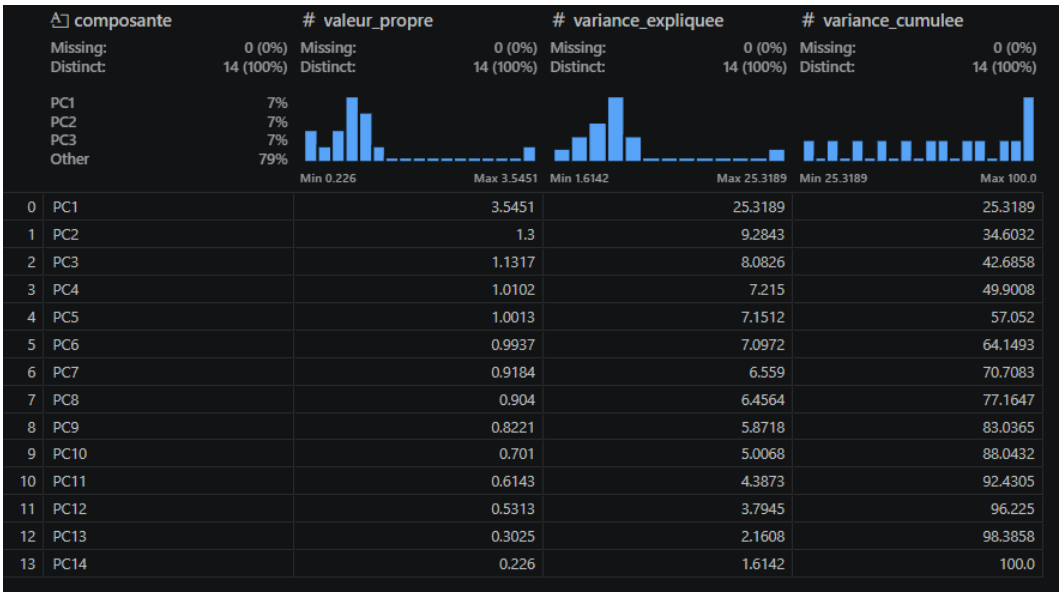


FIGURE 5.2 – Variance cumulée des composantes principales

TABLE 5.1 – Choix des composantes selon l'objectif d'analyse

Objectif	**Composantes retenues**	**Variance cumulée**
Visualisation principale	PC1 et PC2	34,60%
Interprétation des composantes	PC1, PC2 et PC3	42,69%
Conservation d'une plus grande part d'information	8 premières composantes	77,16%



	composante	# valeur_propre	# variance_expliquee	# variance_cumulee
	Missing: 0 (0%) Distinct: 14 (100%)	Missing: 0 (0%) Distinct: 14 (100%)	Missing: 0 (0%) Distinct: 14 (100%)	Missing: 0 (0%) Distinct: 14 (100%)
	PC1 7% PC2 7% PC3 7% Other 79%	Min 0.226 Max 3.5451	Min 1.6142 Max 25.3189	Min 25.3189 Max 100.0
0	PC1	3.5451	25.3189	25.3189
1	PC2	1.3	9.2843	34.6032
2	PC3	1.1317	8.0826	42.6858
3	PC4	1.0102	7.215	49.9008
4	PC5	1.0013	7.1512	57.052
5	PC6	0.9937	7.0972	64.1493
6	PC7	0.9184	6.559	70.7083
7	PC8	0.904	6.4564	77.1647
8	PC9	0.8221	5.8718	83.0365
9	PC10	0.701	5.0068	88.0432
10	PC11	0.6143	4.3873	92.4305
11	PC12	0.5313	3.7945	96.225
12	PC13	0.3025	2.1608	98.3858
13	PC14	0.226	1.6142	100.0

FIGURE 5.3 – Extrait du tableau de variance expliquée par composante

Résultat clé

Les deux premières composantes ne résument pas toute la structure du dataset, mais elles constituent le meilleur plan bidimensionnel pour visualiser les observations. Les trois premières composantes sont utilisées pour l'interprétation, tandis que les huit premières permettent de conserver une part plus importante de la variance totale.

La première composante explique environ un quart de l'information totale. Cela signifie qu'il existe une dimension principale forte, mais non suffisante pour résumer à elle seule le dataset. Les composantes suivantes apportent chacune une information complémentaire. Le seuil de 77,16% atteint avec les huit premières composantes montre qu'une réduction de dimension est possible, mais que la structure des annonces reste relativement riche.

5.2 Analyse des loadings

Les loadings permettent d'identifier les variables les plus influentes dans chaque composante principale. Ils correspondent aux coefficients des variables initiales dans les composantes.

	Unnamed: 0	# PC1	# PC2	# PC3	# PC4	# PC5
	Missing:	0 (0%)	0 (0%)	0 (0%)	0 (0%)	0 (0%)
	Distinct:	14 (100%)	14 (100%)	14 (100%)	14 (100%)	14 (100%)
0	host_response_rate	-0.0125483955968204	-0.12898994569916876	0.2237286706697705	0.6237592255387063	0.5256924300846457
1	host_listings_count	0.0322931429104332	0.3035572045825097	-0.0667535729835778	-0.1295224288206289	-0.1981173560379548
2	latitude	-0.0298030413678375	-0.2341285897795883	-0.4704678653303441	0.2874059026041947	0.2153191077792666
3	longitude	-0.0590970551263933	-0.3875142264144411	-0.4500818270432946	-0.1594999415425655	0.1808519422320248
4	accommodates	0.4459461203803505	-0.2000665521745903	-0.0392112016862355	0.0479122465798047	-0.107889737412883
5	bedrooms	0.4388130917663534	-0.2117686869827464	-0.0854183520733702	-0.0052424591937566	-0.0575449043642811
6	bathrooms	0.3352501247230146	-0.055651799475391	0.0742711551057781	0.031980788335274	0.0178296594527276
7	beds	0.4319060863862856	-0.2085012181858512	-0.0597405067157057	0.0305852524996067	-0.1012013068789502
8	price	0.3670991575168583	0.1598575395924297	0.1360597772781439	0.0290667593842358	0.0188556573164473
9	cleaning_fee	0.3269897314259753	0.2844384756255489	0.0519754559638283	-0.0027379375098375	0.1677299593095084
10	security_deposit	0.2463858576655493	0.3622738140528411	-0.0919653252346467	-0.1333022937967147	0.2976769961897569
11	minimum_nights	0.0099547120640931	0.4614003112833443	-0.2457639257742245	0.0286505774387524	0.4210250048104323
12	maximum_nights	-0.0126075746614294	0.2583403055331574	-0.1487548519979435	0.6798600138679866	-0.519680953393471
13	number_of_reviews	-0.0375567320336835	-0.1935373502172074	0.6256657158364276	0.0131271155127417	0.1240371281424214

FIGURE 5.4 – Extrait du tableau des loadings de PC1 à PC5

Le tableau des loadings montre que les composantes ne sont pas construites à partir d'une seule variable, mais à partir de combinaisons de variables. Les variables ayant les coefficients les plus élevés en valeur absolue sont les plus utiles pour interpréter chaque axe factoriel.

5.2.1 Plan PC1–PC2

Le plan PC1–PC2 met en évidence deux dimensions principales. PC1 est fortement associé aux variables de capacité et de prix, tandis que PC2 est davantage lié aux conditions de réservation et à la gestion de l'annonce.

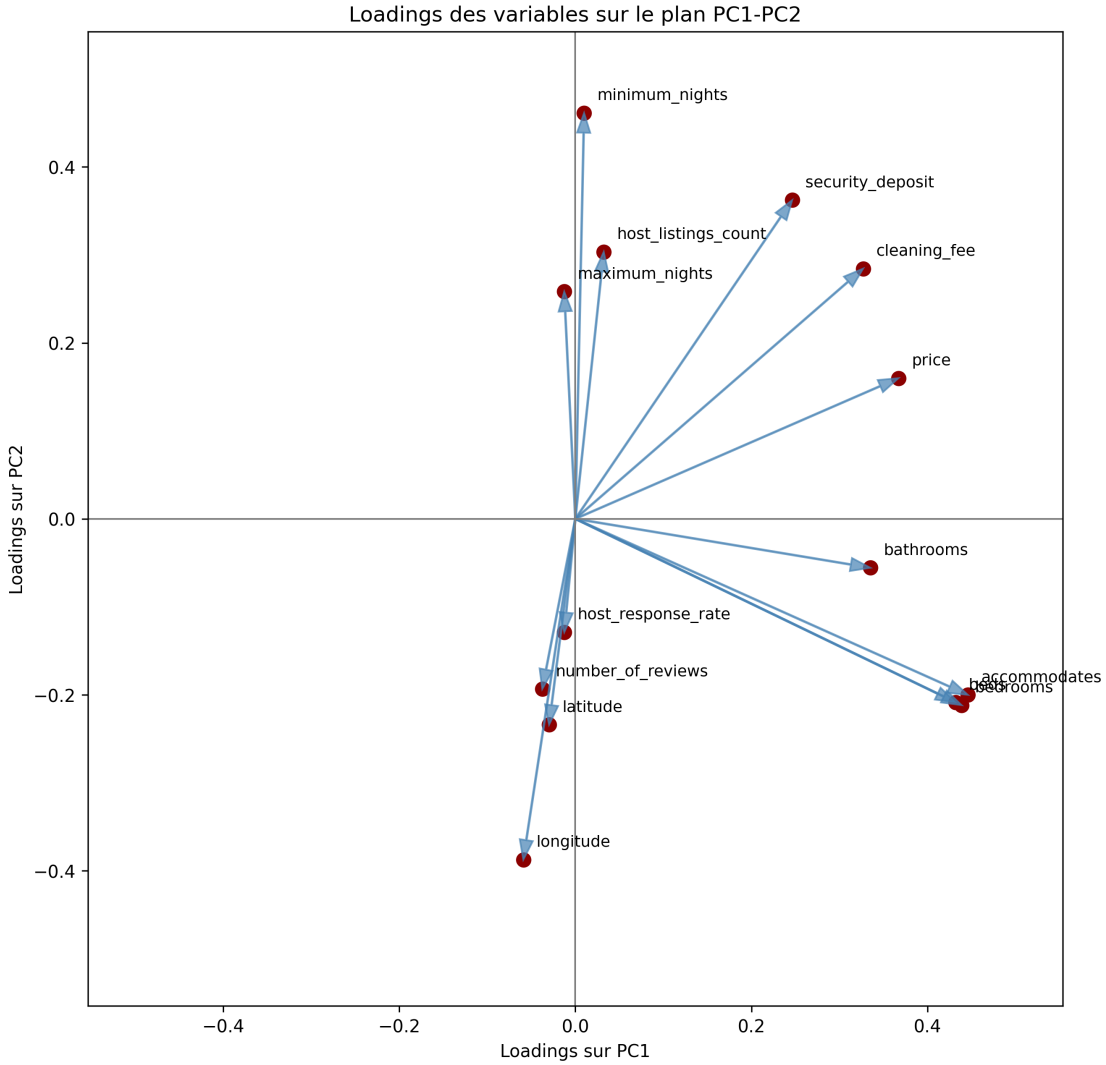


FIGURE 5.5 – Loadings des variables sur le plan PC1–PC2

5.2.2 Plan PC1–PC3

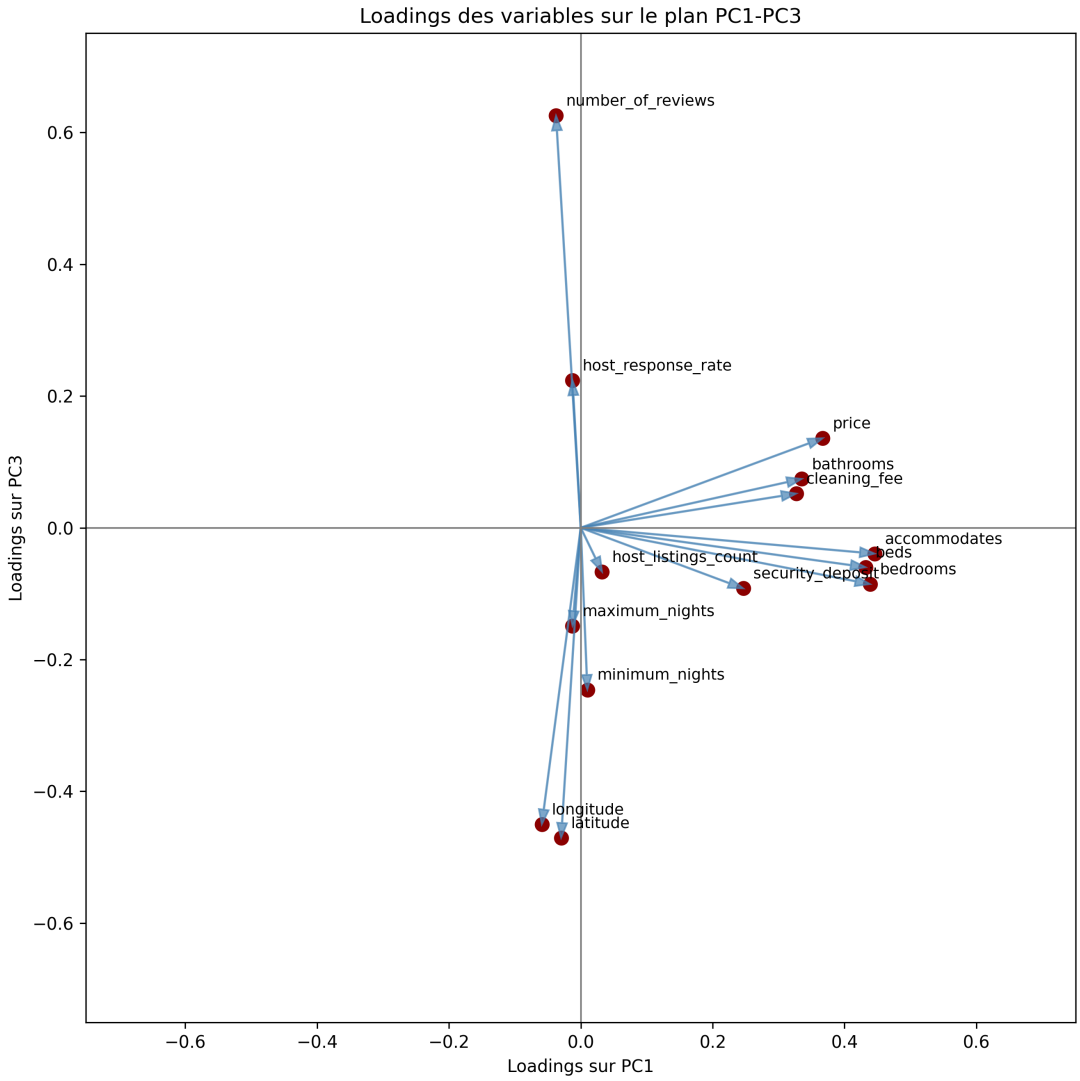


FIGURE 5.6 – Loadings des variables sur le plan PC1–PC3

Le plan PC1–PC3 confirme l'interprétation de PC1 et fait apparaître plus clairement la variable `number_of_reviews`, fortement liée à PC3. Cette troisième composante apporte donc une lecture complémentaire liée à l'activité et à la popularité des annonces.

5.3 Projection des individus

La projection des individus permet d'observer la répartition des annonces Airbnb dans l'espace factoriel. Chaque point représente une annonce.

Le nuage de points présente une forte concentration autour de l'origine, ce qui indique que la majorité des logements possèdent des caractéristiques relativement proches. Quelques points éloignés apparaissent également, suggérant la présence d'annonces atypiques, généralement

	Unnamed: 0	# PC1	# PC3
	Missing: 0 (0%) Distinct: 14 (100%)	Missing: 0 (0%) Distinct: 14 (100%)	Missing: 0 (0%) Distinct: 14 (100%)
	host_response_rate 7% host_listings_count 7% latitude 7% Other 79%	Min -0.059097055... Max 0.445946120...	Min -0.470467865... Max 0.625665715...
0	host_response_rate	-0.0125483955968204	0.2237286706697705
1	host_listings_count	0.0322931429104332	-0.0667535729835778
2	latitude	-0.0298030413678375	-0.4704678653303441
3	longitude	-0.0590970551263933	-0.4500818270432946
4	accommodates	0.4459461203803505	-0.0392112016862355
5	bedrooms	0.4388130917663534	-0.0854183520733702
6	bathrooms	0.3352501247230146	0.0742711551057781
7	beds	0.4319060863862856	-0.0597405067157057
8	price	0.3670991575168583	0.1360597772781439
9	cleaning_fee	0.3269897314259753	0.0519754559638283
10	security_deposit	0.2463858576655493	-0.0919653252346467
11	minimum_nights	0.0099547120640931	-0.2457639257742245
12	maximum_nights	-0.0126075746614294	-0.1487548519979435
13	number_of_reviews	-0.0375567320336835	0.6256657158364276

FIGURE 5.7 – Sous-tableau des loadings pour le plan PC1–PC3

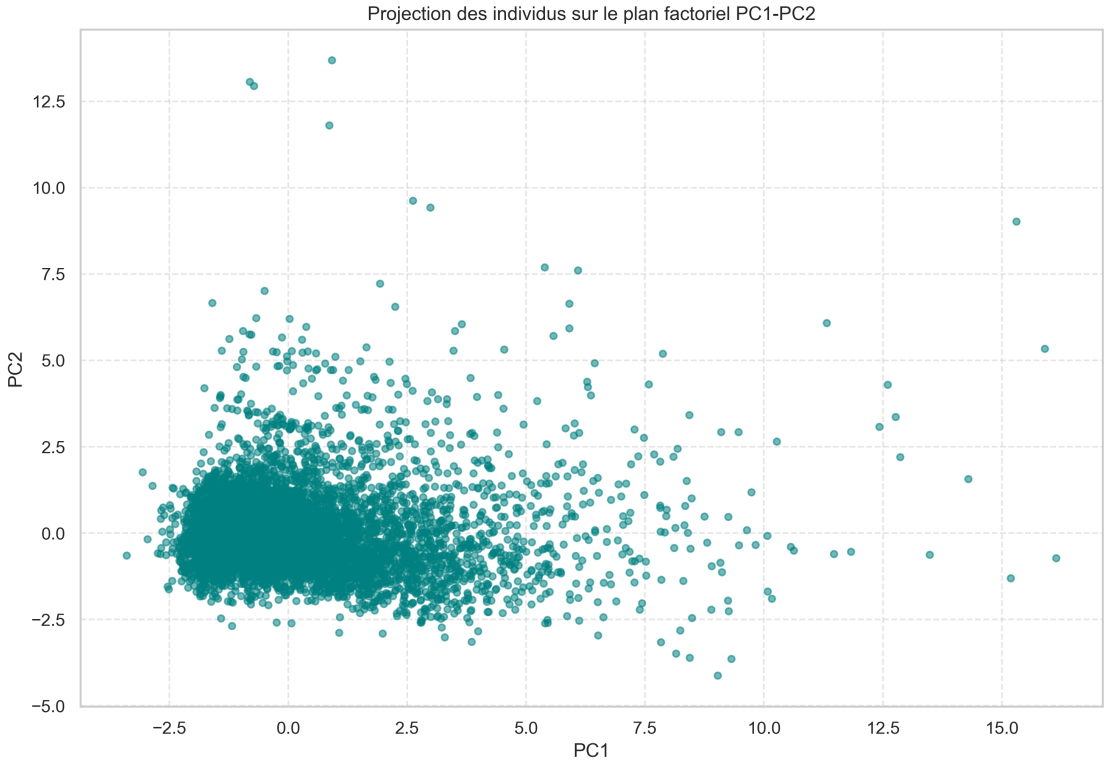


FIGURE 5.8 – Projection des individus sur le plan factoriel PC1–PC2

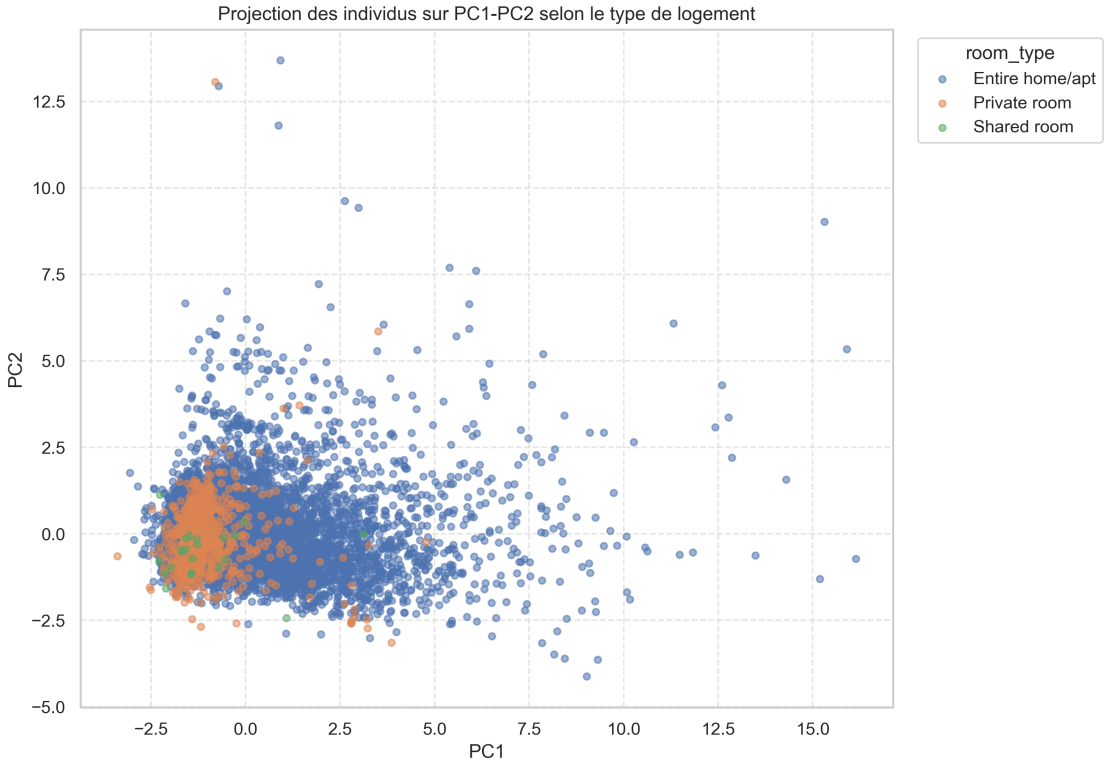


FIGURE 5.9 – Projection des individus selon le type de logement

plus grandes, plus coûteuses ou soumises à des conditions particulières.

La projection colorée par type de logement montre que les logements de type *Entire home/apt* sont les plus dispersés, tandis que les *Private room* et *Shared room* se concentrent davantage dans des zones correspondant à des logements plus modestes.

Chapitre 6

Interprétation des résultats

6.1 Interprétation de PC1 : standing et capacité

La première composante principale est principalement portée par les variables `accommodates`, `bedrooms`, `beds`, `bathrooms`, `price`, `cleaning_fee` et `security_deposit`.

Cette composante peut être interprétée comme un axe de **standing-capacité**. Elle oppose les logements de petite taille, généralement moins chers, aux logements plus grands, mieux équipés et plus coûteux.

Insight analytique

Le prix n'apparaît pas comme une variable isolée : il est lié à une logique globale de taille, d'équipement et de niveau de service du logement.

6.2 Interprétation de PC2 : conditions de location

La deuxième composante principale est influencée par les variables `minimum_nights`, `security_deposit`, `cleaning_fee`, `maximum_nights` et `host_listings_count`.

Elle peut être interprétée comme un axe de **conditions de location et de gestion**. Les annonces ayant un score élevé sur cette composante sont davantage caractérisées par des contraintes de réservation, des frais ou des dépôts plus importants.

Cette dimension ne décrit pas directement la qualité physique du logement, mais plutôt la manière dont l'annonce est gérée et proposée sur la plateforme.

6.3 Interprétation de PC3 : activité et popularité

La troisième composante principale est fortement associée à `number_of_reviews` et, dans une moindre mesure, à `host_response_rate`.

Elle peut être interprétée comme un axe d'**activité et de popularité**. Les annonces ayant un nombre élevé d'avis semblent constituer une dimension spécifique, distincte de la taille ou du prix du logement.

Insight analytique

L'activité observée d'une annonce, mesurée par le nombre d'avis, constitue une dimension propre du dataset. Une annonce peut être grande ou petite, chère ou non, tout en étant plus ou moins active sur la plateforme.

6.4 Synthèse métier

L'ACP permet de distinguer plusieurs profils d'annonces :

— des logements spacieux et coûteux, adaptés aux groupes ou aux familles ;
— des annonces plus encadrées, caractérisées par des conditions de réservation plus strictes ;
— des annonces plus actives, associées à un nombre d'avis plus important.

Ainsi, les annonces Airbnb étudiées ne se différencient pas uniquement par le prix, mais par un ensemble de dimensions complémentaires : taille du logement, conditions de location, niveau d'activité et type d'offre.

TABLE 6.1 – Synthèse finale de l'interprétation des axes principaux

Axe	Interprétation	Variables associées
PC1	Standing et capacité	`accommodates`, `bedrooms`, `beds`, `bathrooms`, `price`, `cleaning_fee`
PC2	Conditions de location et gestion	`minimum_nights`, `maximum_nights`, `security_deposit`, `host_listings_count`
PC3	Activité et popularité	`number_of_reviews`, `host_response_rate`

Chapitre 7

Améliorations possibles

L'ACP réalisée dans ce projet présente plusieurs limites.

Premièrement, les variables catégorielles n'ont pas été intégrées directement dans l'analyse principale. Or, des variables comme `room_type` ou `zipcode` peuvent contenir une information importante. Une amélioration possible serait d'utiliser une méthode adaptée aux données mixtes, comme l'Analyse Factorielle des Données Mixtes (FAMD), ou une Analyse des Correspondances Multiples (ACM) pour les variables qualitatives.

Deuxièmement, certaines variables présentent des valeurs extrêmes, notamment le prix, le dépôt de garantie ou le nombre maximal de nuits. Une transformation logarithmique ou une ACP robuste pourrait être envisagée afin de réduire l'effet des outliers.

Enfin, l'analyse pourrait être prolongée par un clustering sur les premières composantes principales, afin d'identifier automatiquement des groupes d'annonces similaires.

Chapitre 8

Conclusion

Ce projet a permis d'appliquer l'Analyse en Composantes Principales à un dataset Airbnb afin de réduire la dimension des données et d'en extraire les principales structures.

L'analyse descriptive a d'abord montré que les annonces étudiées sont caractérisées par des variables hétérogènes : capacité du logement, prix, frais, dépôt de garantie, durée de séjour, localisation et activité mesurée par le nombre d'avis. Cette diversité a nécessité une préparation rigoureuse des données, notamment la conversion des variables textuelles en variables numériques, la suppression d'une variable entièrement vide, l'imputation des valeurs manquantes par la médiane et la standardisation des variables quantitatives.

L'analyse a ensuite montré que les annonces Airbnb ne sont pas organisées autour d'un seul facteur dominant, mais selon plusieurs dimensions complémentaires. La première composante principale traduit une dimension de standing et de capacité du logement. La deuxième composante reflète les conditions de location et le niveau de contrainte imposé par les hôtes. La troisième composante met en évidence l'activité et la popularité des annonces.

Les visualisations obtenues confirment ces interprétations. La projection des individus montre une concentration importante de logements standards ainsi que quelques annonces atypiques. L'utilisation de la variable `room_type` en lecture complémentaire permet également d'observer des différences cohérentes entre les types de logements.

Malgré certaines limites, notamment l'exclusion des variables catégorielles de l'ACP principale et la présence d'outliers, l'ACP s'est révélée pertinente pour explorer la structure du dataset. Elle a permis de synthétiser l'information contenue dans plusieurs variables quantitatives et de faire émerger des dimensions interprétables dans un contexte réel Airbnb.